

Decision Tree — Metode Entropy

Tugas Kecerdasan Komputasional

Definisi

Pengukuran impurity yang digunakan adalah *Entropy* (Shannon). Entropy bernilai 0 pada node *pure* dan maksimum saat distribusi kelas merata.

Entropy :

$$H(S) = - \sum p_i \cdot \log_2(p_i)$$

Information Gain :

$$IG(S, A) = H(S) - \sum_v [|S_v| / |S|] \cdot H(S_v)$$

Fitur dengan IG terbesar dipilih sebagai simpul pemisah.

1. Dataset Pelanggan

ID	Usia	Status	Membeli (Keputusan)
1	Muda	Mahasiswa	Ya
2	Muda	Mahasiswa	Ya
3	Muda	Mahasiswa	Ya
4	Muda	Mahasiswa	Ya
5	Muda	Pekerja	Ya
6	Muda	Pekerja	Tidak
7	Tua	Mahasiswa	Ya
8	Tua	Pekerja	Ya
9	Tua	Pekerja	Ya
10	Tua	Pekerja	Tidak
11	Tua	Pekerja	Tidak
12	Tua	Pekerja	Tidak

Tabel 1. Dataset Pelanggan ($n = 12$; Ya = 7, Tidak = 5)

1.1 Soal 1 — Membangun Pohon Keputusan

Langkah 1. Entropy simpul akar (seluruh dataset)

$$H(S) = -(7/12) \log_2(7/12) - (5/12) \log_2(5/12)$$

$$= 0,4537 + 0,5263 = 0.9799 \text{ bit}$$

Langkah 2. Information Gain fitur Usia

Usia	n	Ya	Tidak	H
Muda	6	5	1	0.6500
Tua	6	2	4	0.9183

$$H(\text{Muda}) = -(5/6) \log_2(5/6) - (1/6) \log_2(1/6) = 0.6500$$

$$H(\text{Tua}) = -(2/6) \log_2(2/6) - (4/6) \log_2(4/6) = 0.9183$$

$$IG(\text{Usia}) = 0.9799 - [(6/12) \cdot 0.6500 + (6/12) \cdot 0.9183]$$

$$= 0.9799 - 0.7842 = 0.1957$$

Langkah 3. Information Gain fitur Status

Status	n	Ya	Tidak	H
Mahasiswa	5	5	0	0.0000
Pekerja	7	2	5	0.8631

$$H(\text{Mahasiswa}) = 0 \text{ (semua data berkelas Ya — simpul pure)}$$

$$H(\text{Pekerja}) = -(2/7) \log_2(2/7) - (5/7) \log_2(5/7) = 0.8631$$

$$IG(\text{Status}) = 0.9799 - [(5/12) \cdot 0 + (7/12) \cdot 0.8631]$$

$$= 0.9799 - 0.5035 = 0.4764$$

Langkah 4. Pemilihan simpul akar

Fitur	Information Gain	Keterangan
Usia	0.1957	
Status	0.4764	Terbesar → dipilih sebagai akar

Langkah 5. Cabang *Status* = *Mahasiswa* menghasilkan simpul daun langsung (*pure*, semua *Ya*).

Cabang *Status* = *Pekerja* (7 data) dilanjutkan dengan pemisahan pada fitur *Usia*.

Sub-dataset Pekerja ($n = 7$):

Muda + Pekerja : ID 5 (Ya), ID 6 (Tidak) $\rightarrow 1$ Ya, 1 Tidak

Tua + Pekerja : ID 8,9 (Ya), ID 10,11,12 (Tidak) $\rightarrow 1$ Ya, 4 Tidak

$$H(\text{Muda}|\text{Pekerja}) = -(1/2) \log_2(1/2) - (1/2) \log_2(1/2) = 1.0000$$

$$H(\text{Tua}|\text{Pekerja}) = -(1/5) \log_2(1/5) - (4/5) \log_2(4/5) = 0.7219$$


$$IG(\text{Usia}|\text{Pekerja}) = 0.8631 - [(2/7) \cdot 1.0000 + (5/7) \cdot 0.7219] = 0.0617$$

Hasil daun:

Muda + Pekerja $\rightarrow$ YA (tie-break: mayoritas atau kelas positif)

Tua + Pekerja $\rightarrow$ TIDAK (4 dari 5 data)

Pohon keputusan yang dihasilkan:



Gambar 1. Pohon keputusan — Dataset Pelanggan (Entropy)

1.2 Soal 2 — Prediksi Data Uji

Data uji: Usia = Tua, Status = Pekerja

(1) *Simpul akar — Status:*

nilai 'Pekerja' → masuk cabang kanan (Pekerja).

(2) *Simpul kedua — Usia:*

nilai 'Tua' → masuk cabang kanan (Tua).

(3) *Simpul daun: TIDAK.*

Prediksi: TIDAK MEMBELI (1 Ya vs 4 Tidak pada simpul Tua + Pekerja)

2. Dataset Persetujuan Kredit

ID	Pekerjaan	Gaji (juta Rp)	Disetujui
1	PNS	5	Ya
2	PNS	6	Ya
3	PNS	4	Ya
4	PNS	7	Ya
5	PNS	3	Tidak
6	Swasta	3	Tidak
7	Swasta	4	Tidak
8	Swasta	5	Tidak
9	Swasta	8	Ya
10	Swasta	9	Ya
11	Wirausaha	2	Tidak
12	Wirausaha	6	Ya
13	Wirausaha	7	Ya
14	Wirausaha	3	Tidak

Tabel 2. Dataset Kredit ($n = 14$; Ya = 8, Tidak = 6)

2.1 Soal 3 — Membangun Pohon Keputusan

Langkah 1. Entropy simpul akar

$$\begin{aligned}
 H(S) &= -(8/14) \log_2(8/14) - (6/14) \log_2(6/14) \\
 &= 0,4614 + 0,5239 = 0.9852 \text{ bit}
 \end{aligned}$$

Langkah 2. Information Gain fitur *Pekerjaan*

Pekerjaan	n	Ya	Tidak	H
PNS	5	4	1	0.7219
Swasta	5	2	3	0.9710
Wirausaha	4	2	2	1.0000

$$H(PNS) = -(4/5) \log_2(4/5) - (1/5) \log_2(1/5) = 0.7219$$

$$H(Swasta) = -(2/5) \log_2(2/5) - (3/5) \log_2(3/5) = 0.9710$$

$$H(Wirusaha) = -(2/4) \log_2(2/4) - (2/4) \log_2(2/4) = 1.0000$$

$$\begin{aligned} IG(Pekerjaan) &= 0.9852 - [(5/14) \cdot 0.7219 + (5/14) \cdot 0.9710 + (4/14) \cdot 1.0000] \\ &= 0.9852 - 0.8903 \\ &= 0.0949 \end{aligned}$$

Langkah 3. Information Gain fitur *Gaji* — penentuan threshold

Karena *Gaji* bersifat numerik, semua titik potong di antara nilai berurutan dievaluasi. Threshold $t = 6,5$ menghasilkan IG terbesar.

$$Gaji \leq 6,5 \text{ jt} \rightarrow ID \ 1(5,Ya), 2(6,Ya), 3(4,Ya), 5(3,T), 6(3,T), 7(4,T),$$

$$8(5,T), 11(2,T), 12(6,Ya), 14(3,T) \rightarrow n=10, Ya=4, Tidak=6$$

$$Gaji > 6,5 \text{ jt} \rightarrow ID \ 4(7,Ya), 9(8,Ya), 10(9,Ya), 13(7,Ya) \rightarrow n=4, Ya=4, Tidak=0$$

$$H(Gaji \leq 6,5) = -(4/10) \log_2(4/10) - (6/10) \log_2(6/10) = 0.9710$$

$$H(Gaji > 6,5) = 0 \text{ (simpul pure — semua Ya)}$$

$$\begin{aligned} IG(Gaji, t=6,5) &= 0.9852 - [(10/14) \cdot 0.9710 + (4/14) \cdot 0] \\ &= 0.9852 - 0.6935 \\ &= 0.2917 \end{aligned}$$

Langkah 4. Pemilihan simpul akar

Fitur	Information Gain	Keterangan
Pekerjaan	0.0949	
Gaji ($t=6,5$)	0.2917	Terbesar → dipilih sebagai akar

Langkah 5. Cabang *Gaji* $> 6,5$ menghasilkan simpul daun YA (*pure*). Cabang *Gaji* $\leq 6,5$ (10 data) dilanjutkan dengan fitur Pekerjaan.

Sub-dataset Gaji $\leq 6,5$ ($n = 10$, Ya = 4, Tidak = 6):

PNS : ID 1(Ya), 2(Ya), 3(Ya), 5(T) $\rightarrow$ 3 Ya, 1 Tidak ($n=4$)

Swasta : ID 6(T), 7(T), 8(T) $\rightarrow$ 0 Ya, 3 Tidak ($n=3$, pure)

Wirausaha : ID 11(T), 12(Ya), 14(T) $\rightarrow$ 1 Ya, 2 Tidak ($n=3$)

$$H(\text{PNS}|\text{sub}) = 0.8113$$

$$H(\text{Swasta}|\text{sub}) = 0 \text{ (pure)}$$

$$H(\text{Wirausaha}|\text{sub}) = 0.9183$$

$$IG(\text{Pekerjaan}|\text{sub}) = 0.9710 - [(4/10) \cdot 0.8113 + (3/10) \cdot 0 + (3/10) \cdot 0.9183]$$


$$= 0.9710 - 0.6000$$

$$= 0.3710$$

Daun yang dihasilkan:

PNS (3Y,1T) $\rightarrow$ YA | Swasta (0Y,3T) $\rightarrow$ TIDAK | Wirausaha (1Y,2T) $\rightarrow$ TIDAK

Pohon keputusan yang dihasilkan:



Gambar 2. Pohon keputusan — Dataset Kredit (Entropy)

3. Soal 4 — Node Impurity Fitur Pekerjaan

Dihitung dari dataset kredit lengkap ($n = 14$, $Ya = 8$, $Tidak = 6$, $H(S) = 0.9852$ bit).

3.1 Soal 4a — Multi-way Split: PNS | Swasta | Wirausaha

Pekerjaan	n	Ya	Tidak	H
PNS	5	4	1	0.7219
Swasta	5	2	3	0.9710
Wirausaha	4	2	2	1.0000

Node impurity (entropy terbobot):

$$H_{\text{multi}} = (5/14) \cdot 0.7219 + (5/14) \cdot 0.9710 + (4/14) \cdot 1.0000$$

$$= 0.2578 + 0.3468 + 0.2857$$

$$= 0.8903$$

$$IG(\text{multi-way}) = 0.9852 - 0.8903 = 0.0949$$

Multi-way split → Node Impurity = 0.8903 IG = 0.0949

3.2 Soal 4b — Binary Split: {PNS} vs {Swasta, Wirausaha}

Kelompok	n	Ya	Tidak	H
{PNS}	5	4	1	0.7219
{Swasta, Wirausaha}	9	4	5	0.9911

{PNS}: $Ya = 4$, $Tidak = 1 \rightarrow H = 0.7219$ (sudah dihitung)

{Swasta, Wirausaha}: ID 6,7,8,9,10,11,12,13,14 $\rightarrow Ya = 4$, $Tidak = 5$ ($n = 9$)

$$H(\text{Swasta} \cup \text{Wirausaha}) = -(4/9) \log_2(4/9) - (5/9) \log_2(5/9) = 0.9911$$

Node impurity (entropy terbobot):

$$H_{\text{binary}} = (5/14) \cdot 0.7219 + (9/14) \cdot 0.9911$$

$$= 0.2578 + 0.6371$$

$$= 0.8950$$

$$IG(\text{binary}) = 0.9852 - 0.8950 = 0.0903$$

Binary split $\rightarrow$ Node Impurity = 0.8950 IG = 0.0903

3.3 Perbandingan

Metode Split	Node Impurity	Information Gain	Lebih Baik?
Multi-way (3 cabang)	0.8903	0.0949	Ya
Binary ({PNS} vs rest)	0.8950	0.0903	

Multi-way split menghasilkan node impurity lebih rendah ($0.8903 < 0.8950$) dan information gain lebih besar ($0.0949 > 0.0903$), sehingga **multi-way split lebih baik** untuk fitur Pekerjaan.